Raport — Laboratorium 03

Zespół: Kacper Piotrowski G., Igor Ptak **Data:** 29.10.2026

Środowisko

Parametr	Wartość
Wersja Ollama	nie dotyczy - modele uruchamiane zdalnie przez API PCSS
Sprzęt (CPU/GPU, RAM)	infrastruktura HPC PCSS (inferencja po stronie serwera); klient: skrypt Python 3 (biblioteka standardowa)
Modele	`DeepSeek-V4-Flash`, `GLM-5.3-Flash`
Liczba dostępnych notatek	172 (39 unikalnych treści — notatki się powtarzają)

Zamiast aplikacji C# z Ollamą użyto własnego skryptu w Pythonie, który odtwarza te same eksperymenty (ten sam zbiór notatek, przykłady z `prompt-examples.csv`, metryki z EXP-00). Każda unikalna notatka jest wysyłana do modelu raz (w EXP-03 trzy razy), a wynik przypisywany wszystkim jej wystąpieniom; metryki liczone są na wszystkich 172 rekordach.

EXP-00 — Sposób oceny wyników

Zbiór wzorcowy powstał przez ręczne oetykietowanie `data/labeled-notes.csv` zgodnie z interpretacją z `readme.md`:

- `floor` — jedno piętro docelowe (parter = 0, poziom -1 = -1, cyfry rzymskie zamieniane na arabskie); `null`, gdy brak piętra **lub notatka wymienia kilka pięter** (np. „dostawy na 3, 2, 1 piętro oraz na -1"),
- `elevator` — `true` / `false` / `null`; „samochód z windą" to winda w pojeździe, nie w budynku → `null`.

Rozkład wzorca: 103 rekordy bez żadnej informacji (`null`/`null`), 69 z piętrem, 11 z informacją o windzie. Duża liczba „pustych" notatek sprawdza, czy model nie dopowiada danych.

Metryka	Definicja
Floor accuracy	odsetek rekordów, w których `floor` modelu = `floor` wzorca (`null` = `null` liczy się jako trafienie)
Elevator accuracy	odsetek rekordów, w których `elevator` modelu = `elevator` wzorca
Exact match	odsetek rekordów, w których oba pola są poprawne jednocześnie
Poprawny JSON	odsetek odpowiedzi, z których da się odczytać obiekt `{floor: int|null, elevator: bool|null}`
Średni czas	średni czas odpowiedzi API na jedną notatkę

Metryka	Definicja
Powtarzalne notatki	liczba unikalnych notatek (z 39), dla których wszystkie powtórzenia dały identyczną odpowiedź

Odpowiedź niesparsowana (zły JSON) liczona jest jako błędna w obu polach.

EXP-01 — Porównanie modeli

Prompt few-shot (4 przykłady), temperature 0.0, tryb JSON (`response_format: json_object`).

Model	Floor accuracy	Elevator accuracy	Exact match	Średni czas [ms]
DeepSeek-V4-Flash	99,4%	100,0%	99,4%	~560 (330–560 w kolejnych przebiegach)
GLM-5.3-Flash	100,0%	100,0%	100,0%	~1160 (1090–1230 w kolejnych przebiegach)

Exact match oznacza odsetek notatek, dla których model poprawnie rozpoznał jednocześnie oba pola: `floor` i `elevator`.

Wnioski:

- Oba modele są praktycznie bezbłędne; jedyny błąd DeepSeeka to notatka „1 piętro, od windy towarowej. dwa punkty dostaw biuro i magazyn" — model zwrócił `floor: null`, interpretując „dwa punkty dostaw" jako możliwe różne piętra. To raczej niejednoznaczność danych niż „halucynacja".
- GLM jest o ~0,6 pkt proc. dokładniejszy, ale ok. **2–3× wolniejszy**. Przy tak małej różnicy jakości czas odpowiedzi staje się istotnym kryterium.
- Wyniki bliskie 100% oznaczają, że przy dobrym prompcie zadanie jest dla obu modeli łatwe — różnice ujawniają się dopiero w przypadkach granicznych (EXP-02, EXP-03).

EXP-02 — Prompting

Temperature 0.0, tryb JSON. Prompt systemowy we wszystkich wariantach zawiera szczegółowe reguły (parter, cyfry rzymskie, kilka pięter → `null`, winda w samochodzie ≠ winda w budynku). Warianty różnią się liczbą przykładów z `prompt-examples.csv` (0 / 1 / 4).

Wariant	Model	Floor accuracy	Elevator accuracy	Exact match
zero-shot	DeepSeek-V4-Flash	100,0%	100,0%	100,0%
zero-shot	GLM-5.3-Flash	100,0%	100,0%	100,0%
one-shot	DeepSeek-V4-Flash	99,4%	99,4%	98,8%
one-shot	GLM-5.3-Flash	100,0%	100,0%	100,0%
few-shot	DeepSeek-V4-Flash	99,4%	100,0%	99,4%

Wariant	Model	Floor accuracy	Elevator accuracy	Exact match
few-shot	GLM-5.3-Flash	100,0%	100,0%	100,0%

Wnioski:

- Przy precyzyjnym prompcie systemowym przykłady **nie poprawiły** wyników — zero-shot był już bezbłędny. Żadna notatka nie zaczęła być rozpoznawana poprawnie dopiero po dodaniu przykładów.
- U DeepSeeka przykłady wręcz minimalnie zaszkodziły: w one-shot pojawił się błąd `elevator: false` dla notatki z „SAMOCHÓD Z WINDĄ" (wzorzec `null`) — model słusznie uznał, że to nie winda w budynku, ale zamienił „brak informacji" na „brak windy". Jedyny przykład w one-shot („butle są na 1 piętrze" → `elevator: null`) nie pokazuje tej różnicy.
- Wniosek: przykłady są najcenniejsze, gdy prompt jest ubogi; gdy reguły są opisane wprost, liczy się przede wszystkim jakość instrukcji. Ograniczenie: reguły w prompcie były pisane ze znajomością zbioru danych, więc wynik zero-shot jest optymistyczny.

EXP-03 — Temperature

Prompt few-shot, każda z 39 unikalnych notatek wysłana 3 razy (516 ocenionych rekordów na model i temperaturę). Exact match liczony na wszystkich powtórzeniach.

Temperature	Model	Exact match	Powtarzalne notatki
0.0	DeepSeek-V4-Flash	99,4%	39/39
0.0	GLM-5.3-Flash	100,0%	39/39
0.5	DeepSeek-V4-Flash	99,4%	39/39
0.5	GLM-5.3-Flash	100,0%	39/39
1.0	DeepSeek-V4-Flash	98,3%	37/39
1.0	GLM-5.3-Flash	100,0%	39/39

Wnioski:

- Przy T = 1.0 DeepSeek zaczął odpowiadać niedeterministycznie w 2 notatkach:
  - „Telefon przed dostawą!!! 2 PIĘTRO 13kluczyk0000" — w jednym z powtórzeń `floor: 3` zamiast 2 (błąd, którego przy niższej temperaturze nie było),
  - „1 piętro, od windy towarowej..." — raz `1`, raz `null`.
- GLM był w pełni powtarzalny nawet przy T = 1.0 — jego rozkład odpowiedzi jest bardzo „ostry" dla tak prostego zadania.
- Dla agenta ekstrahującego dane wybieramy **T = 0.0** — liczy się powtarzalność i brak przypadkowych błędów. Wyższa temperatura ma sens dla agentów generujących treści (np. wiadomość do klienta), gdzie różnorodność jest zaletą.

EXP-04 — Structured output — JSON i walidacja

Prompt few-shot, temperature 0.0. Porównano trzy sposoby wymuszenia formatu:

Wariant	Model	Poprawny JSON	Exact match
prompt (format tylko opisany w prompcie)	DeepSeek-V4-Flash	100,0%	99,4%
prompt	GLM-5.3-Flash	100,0%	100,0%
json-schema (`response_format: json_schema`, strict)	DeepSeek-V4-Flash	100,0%	99,4%
json-schema	GLM-5.3-Flash	100,0%	100,0%
json_object (tryb JSON bez schematu)	DeepSeek-V4-Flash	100,0%	99,4%
json_object	GLM-5.3-Flash	100,0%	100,0%

Wnioski:

- Oba modele zwracały poprawny składniowo JSON we wszystkich wariantach — dla nowoczesnych modeli i prostego schematu (2 pola) opis w prompcie wystarcza. JSON Schema nadal warto stosować w produkcji, bo daje **gwarancję** formatu, a nie tylko wysokie prawdopodobieństwo.
- **Poprawny JSON nie oznacza poprawnej odpowiedzi**: błędne odpowiedzi DeepSeeka (`{"floor": null, "elevator": true}` dla „1 piętro, od windy towarowej…") były w 100% zgodne ze schematem. Schemat waliduje strukturę i typy, a nie semantykę — do tego potrzebny jest zbiór wzorcowy i metryki z EXP-00.

Najtrudniejsze notatki

Notatka	Wzorzec	Problem
„1 piętro, od windy towarowej. dwa punkty dostaw biuro i magazyn"	`1` / `true`	DeepSeek niemal zawsze zwracał `floor: null` — „dwa punkty dostaw" sugeruje kilka lokalizacji, a reguła „kilka pięter → null" zachęca do ostrożności. Notatka jest faktycznie niejednoznaczna.
„…Dział Logistyki poziom -1 ; DOSTAWY SAMOCHÓD Z WINDĄ…"	`-1` / `null`	Słowo „winda" odnosi się do pojazdu. Bez reguły w prompcie model może uznać to za windę w budynku (`true`); DeepSeek w one-shot przeszedł w drugą skrajność (`false`).
„Telefon przed dostawą!!! 2 PIĘTRO 13kluczyk0000"	`2` / `null`	Liczby w kodzie domofonu („13kluczyk0000") obok piętra — przy T = 1.0 DeepSeek raz zwrócił `3`.

Notatki trudne „z założenia" — kilka pięter („dostawy na 3, 2, 1 piętro oraz na -1", „parter, pierwsze i drugie piętro"), cyfry rzymskie („p. IX", „P. I"), godziny („PRZYJDZIE NA 13"), numery lokali i kody — były rozpoznawane poprawnie przez oba modele we wszystkich wariantach.

Rekomendacja

Model: `DeepSeek-V4-Flash`, **prompt:** zero-shot ze szczegółowymi regułami, **temperature 0.0**, **structured output: JSON Schema**.

Dowody:

- jakość praktycznie równa GLM (99,4–100% exact match vs 100%), a czas odpowiedzi **2–3× krótszy** (~0,3–0,6 s vs ~1,1–1,2 s) — dla agenta przetwarzającego wiele notatek to istotna oszczędność,
- przy T = 0.0 odpowiedzi są w 100% powtarzalne (39/39),
- zero-shot dał najlepszy wynik i najkrótszy prompt (mniej tokenów = niższy koszt i czas),
- JSON Schema gwarantuje format, który agent przetwarza programowo.

Jeżeli priorytetem jest maksymalna dokładność, a czas nie gra roli, lepszym wyborem jest `GLM-5.3-Flash` (100% we wszystkich eksperymentach, pełna powtarzalność nawet przy T = 1.0).

Ograniczenia: zbiór zawiera tylko 39 unikalnych notatek, a reguły w prompcie powstały ze znajomością tych danych — przed wdrożeniem należy zweryfikować wybór na nowych, nieoglądanych notatkach. Różnice między modelami (1–3 rekordy) mieszczą się w granicach, które przy innym zbiorze mogłyby się odwrócić.