Raport — Laboratorium 03

Zespół: Hubert Zalewski, Paweł Zakrzewski
Data: 29.10.2026

Środowisko

Parametr	Wartość
Wersja Ollama	0.40.13
Sprzęt (CPU/GPU, RAM)	Intel Core i5-12400F, NVIDIA GeForce RTX 3070, 16 GB RAM
Liczba dostępnych notatek	170

Modele: `gemma3:4b`, `llama3.2:3b`, `qwen3:4b`. Test na 10 notatkach z `examples.csv`.

EXP-00 — Sposób oceny wyników

Pole jest poprawne tylko przy dokładnej zgodności z oczekiwaną wartością (także `null`). Niepoprawny JSON = błędna odpowiedź.

Metryka	Definicja
Floor accuracy	% notatek z poprawnym `floor`
Elevator accuracy	% notatek z poprawnym `elevator`
Exact match	% notatek z oboma polami poprawnymi (główna metryka)
Średni czas	średni czas odpowiedzi na notatkę [ms]

EXP-01 — Porównanie modeli

Model	Floor accuracy	Elevator accuracy	Exact match	Średni czas [ms]
gemma3:4b	80%	70%	60%	501
llama3.2:3b	80%	50%	40%	136
qwen3:4b	100%	100%	100%	8519

Exact match oznacza odsetek notatek, dla których model poprawnie rozpoznał jednocześnie oba pola: `floor` i `elevator`.

Wnioski: qwen3 bezbłędny, ale ok. 17× wolniejszy od gemmy (tryb myślenia). Mniejsze modele lepiej radzą sobie z piętrem niż z windą.

EXP-02 — Prompting

Model	Wariant	Floor accuracy	Elevator accuracy	Exact match
gemma3:4b	zero-shot	80%	70%	60%
gemma3:4b	one-shot	100%	90%	90%
gemma3:4b	few-shot	80%	90%	70%
llama3.2:3b	zero-shot	80%	50%	40%
llama3.2:3b	one-shot	90%	60%	50%
llama3.2:3b	few-shot	70%	50%	20%
qwen3:4b	wszystkie	100%	100%	100%

Wnioski: one-shot najbardziej pomaga mniejszym modelom. Few-shot wypadł gorzej niż one-shot, a dla llamy nawet gorzej niż zero-shot. Qwen nie potrzebuje przykładów.

EXP-03 — Temperature

Model	Temperature	Exact match	Powtarzalne notatki
gemma3:4b	0.0 / 0.5 / 1.0	60% / 60% / 62%	
llama3.2:3b	0.0 / 0.5 / 1.0	40% / 40% / 28%	
qwen3:4b	0.0 / 0.5 / 1.0	100% / 100% / 100%	10/10

Wnioski: temperatura 0 jest najlepsza do ekstrakcji. Przy 1.0 llama wyraźnie traci jakość (i raz zwróciła niepoprawny JSON). Qwen jest odporny na temperaturę.

EXP-04 — Structured output — JSON i walidacja

Model	Wariant	Poprawny JSON	Exact match
gemma3:4b	prompt	10/10	60%
gemma3:4b	json-schema	10/10	70%
llama3.2:3b	prompt	10/10	40%
llama3.2:3b	json-schema	10/10	40%
qwen3:4b	prompt	10/10	100%
qwen3:4b	json-schema	10/10	100%

Wnioski: w wariancie `prompt` modele owijały JSON w markdown i trzeba go było czyścić w kodzie. `json-schema` zwraca od razu czysty JSON, nie pogarsza jakości (gemma nawet +10 p.p.) i jest szybszy dla mniejszych modeli.

Najtrudniejsze notatki

- **NOTE-010** „Winda nie działa” — modele dają `false`, a chodzi o obecność windy.
- **NOTE-007** „winda tylko do 3” — myli się piętro albo winda.
- **NOTE-003** / **NOTE-004** — brak info o windzie, modele dopowiadają `false`.
- **NOTE-009** „Drugie lub trzecie” — powinno być `null`.

Małe modele wolą zgadnąć niż zwrócić `null`.

Rekomendacja

qwen3:4b + zero-shot + json-schema, temperatura 0. Jedyny model ze 100% exact match we wszystkich eksperymentach. Minus: kilka sekund na notatkę. Gdy liczy się szybkość, wybieramy gemma3:4b z one-shot i json-schema. Zbiór testowy ma tylko 10 notatek, więc wyniki warto potwierdzić na większej próbie.